

Website: http://www.4esoft.com +4 031 4055287 +4 031 4012234 +4 0721 368 127

email: office@4esoft.com

Client experimental GoDriveCarBox

Arhitectura modelelor de predictie a defectarii componetelor autovehiculului

Proiect	GoDrive
Beneficiar	GODRIVE SRL
Contract	Nr. 2/25.11.2016
Data modificare	2017.03.08
Data creere	2017.02.02
Versiune	1.0.0.2
Descriere	Arhitectura modele predictie defecte
	autovehicule

Problema predictiei defectarii componentelor autovehicolului comporta multiple aspecte ce trebuie luate in consideratie la implementare atat din punct de vedere tehnic cat si din punct de vedere al modelarii de date/informatii. In acest sens s-au identificat urmatoarele aspecte:

Tabelul analizei solutiilor arhitecturale

Nr	Problema	Natura	Descriere	Solutie
1	Modelarea	Modelare	In vederea	Se vor folosi modele de predictie
	predictie		determinarii unei	avansate bazate pe tehnologiile
			predictii a unei	actuale ale invatarii automatizate
			potentiale defectari de	(stadiul curent al tehnologiei,
			componenta este	cercetarii si dezvoltarii). S-a optat

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

+4 031 4055287 +4 031 4012234 +4 0721 368 127

email: office@4esoft.com

Nr	Problema	Natura	Descriere	Solutie
			necasara analiza	pentru utilizarea unui model de
			factorilor si a modului	invatarea automatizata bazat pe
			de inferenta a	retele neurale cu multi-nivele
			corelatiei optime.	ascunse. In " Tabelul de descriere a
			Chiar daca statistic se	<i>solutiei de modelare</i> " sunt
			poate determina o	prezentate detaliile propuse ale
			inferenta este	arhitecturii matematice solutiei.
			necesara gasirea unui	
			algoritm auto-	
			adaptabil care sa	
			"invete" sa gaseasca	
			corelatii si sa	
			determine predictii	
2	Metode de	Modelare	Indentificarea	S-au analizat numeroase lucrari
	determinare a		fluxurilor de date ce	stiintifice publicate in ultimii 5 ani
	predictorilor		pot genera potentiale	in domeniul tehnologiilor bazate
			inferente privind	pe Inteligenta Artificiala. Din
			functionarea	aceste lucrari amintim doua dintre
			autovehicolului: avand	ele axate in special pe utilizarea
			un model de baza	sistemelor cu invatare
			matematic este	automatizata in modele de
			necesara	predictibilitate a intretinerii
			determinarea	flotelor de autovehicule si auto-
			variabilelor principale	utilitare:
			si a ponderilor	

Nr

3

Rularea

in mediu

modelului atat

computational

intensiv cat si

in mediu local

Tehnica

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

Natura

Descriere

determinarea functiei

ipoteza de invatare

automata si predictie

Modelul predictiv ales

bazat pe tehnologiile

necesitatii unei puteri

state-of-the-art de

deep leaning are

inconvenientul

acestora in

+4 031 4055287 +4 031 4012234 +4 0721 368 127

Website:

Problema

http://www.4esoft.com

	email: office@4esoft.com
	Solutie
A)	R. Prytz, S. Nowaczyk, T.
	Rögnvaldsson, S. Byttner,
	"Analysis of Truck
	Compressor Failures Based
	on Logged Vehicle Data", in
	In Proceedings of the 9th
	International Conference
	on Data Mining (DMIN'13),
	Las Vegas, NV, USA. July
	2013
B)	T. Rögnvaldsson, S. Byttner,
	R. Prytz, S Nowaczyk,
	"Wisdom of Crowds for
	Self-organized Intelligent
	Monitoring of Vehicle
	Fleets", submitted to IEEE
	Transactions on Knowledge
	and Data Engineering

(TKDE), 2014

modelarii in doua etape:

Solutia aleasa consta in spargerea

A) Etapa de preantrenare a

modelului cu invatare

automatizata la nivelul

Nr

4

Disponibilitatea

datelor la faza

experimentare

de

Modelare

/ Tehnica

In vederea realizarii

automatizata este

procesului de invatare

necesara si obligatorie

existenta unor seturi

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

Natura

si a

Descriere

+4 031 4055287 +4 031 4012234 +4 0721 368 127

Problema

http://www.4esoft.com

email: office@4esoft.com Solutie mari de calcul precum serverului GoDrive. In cadrul acestei etape modelele bazate pe relete neurale adanci vor fi antrenate prin invatare automatizata si se va genera un model initial al ponderilor predictorilor din retele. Se vor utiliza date off-line. B) Etapa de auto-invatare continua la nivelul dispozitivului incorporat GoDrive va asigura ajustarea ponderilor predictorilor si a nivelelor ascunse adanci din retelele neurale in functie de dinamica datelor colectate si analizate din mediul real.

Se vor achizitiona seturi de date

A) UCI Machine Learning

Repository collection of

din surse externe:

email: office@4esoft.com

Website:

http://www.4esoft.com

Nr	Problema	Natura	Descriere		Solutie
			pe baza carora sa se		databases, domain
			faca experimentarea		theories, and data
			modelarii intiale		generators, Center for
			inferentiale		Machine Learning and
					Intelligent Systems
					Bren School of Information
					and Computer Science,
					University of California,
					Irvine
				R)	Vehicle safety defect
				5,	investigations, recalls and
					collision investigations data
					_
					for Great Britain, Driver and
					Vehicle Standards Agency,
					UK

Tabelul de descriere a solutiei de modelare

Algoritm	Model auto-modelare de predictor si predictie a potentialelor	
	defecte in autovehicul	
Versiune	1.0.2	
Data creatiei	2017.02.01	
Data ultimei modificari	2017.04.09	

Website: http://www.4esoft.com

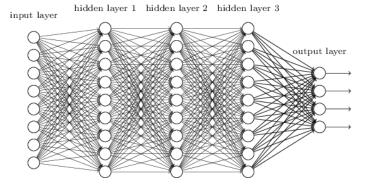
Tip algoritm	Model cu invatare automatizata	
Model de optimizare	Optimizare cu invatare automatizata bazata pe calculul	
	gradientilor erorii functiei de cost	
Descriere generala	Determinarea atat a factorilor care determina defectarea	
	componentelor autovehicolului cat si a momentului in care o	
	anumita componenta se defecteaza poate fi vazuta ca o functie cu	
	complexitate ridicata H(X)=Y multi-variata (considerand X ca fiind	
	un vector de date stohastice generate de catre autovehicol) si	
	multi-nomiala de date (consideram Y ca fiind un vector multi-	
	nomial in care fiecare element reprezinta un rezultat de predictie	
	sau inferenta). Datorita caracterului atat euristic cat si stohastic al	
	procesului de analiza al variabilelor si de determinare a	
	rezultatelor este putin probabila aplicarea unui algoritm complex	
	prin care sa se defineasca functia H(X)=Y, motiv pentru care functia	
	ipoteza H(X) va fi determinata de un model avansat cu invatare	
	automatizata bazat pe retele neurale cu nivele multiple ascunse	
	precum si convolutiile necesare procesului de determinare a	
	variabilelor calculate.	
Date de intrare	Vectorul X de parametrii va contine toate datele obtenabile prin	
	intermediul interfetei On Board Diagnostics	
Date de iesire	In urma analizei literaturii si lucrarilor de specialitate precum si in	
	urma achizitionarii seturilor de date propuse se vor identifica	
	variabilele "tinta" urmarite care sunt in directa corelatie	
	(aproximativ 1-la-1) cu predictia defectarii unuia sau mai multor	
	componente	
Metoda de calcul	Plecand de la premiza ca intreg modelul reprezinta o functie	
	ipoteza de determinare in baza unui vector multi-variat a unui	



Website: http://www.4esoft.com email: office@4esoft.com

rezultat multi-nomial se construieste o retea neurala pe structura intuitiva a neuronilor biologici in care avem:

- Fiecare neuron primeste informatii de la mai multi neuroni conectati de la axoni acestora la dendritele sale
- Neuronul individual realizeaza o peratie liniara dupa care trece rezultatul operatiei liniare printr-o functie non-liniara de activare (de exemplu sigmoid $\sigma(z)=(\frac{1}{1+e^{-z}})$)
- Prin introducerea unui numar mare de neuroni pe nivele multiple se poate "inmagazina" o cantitate mare de informatie in vederea obtinerii unei functii cu complexitate foarte ridicata non-liniara. Un exemplu este dat de imaginea de mai jos:



In vederea calcului functiei ipoteza H(X)=Y se aplica un algoritm de "mers inainte" de forma:

$$A_i = \sigma(A_{i-1} * W_i)$$

Unde W(i) este un vector de ponderi al dendritelor neuronului respectiv ce se aplica intrarilor din neuronii nivelului neural anterior

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

+4 031 4055287 +4 031 4012234 +4 0721 368 127

Website: http://www.4esoft.com

$E = \sqrt{\frac{(Out_{corect} - A_n)^2}{2}}$ $- \text{In final se calculeaza eroarea intre valoarea multi-nomiala asteptata si cea rezultata din functie ipoteza cu:}$ $E = \sqrt{\frac{(Out_{corect} - A_n)^2}{2}}$ $- \text{Invatarea efectiva consta in ajustarea ponderilor} $ $(\text{vectorii/matricile W(i,j) unde i,j reprezinta nivelele retelei neurala) automatizata se realizeaza prin metoda propagarii inapoi a gradientului erorii determinate si prezentate anterior. Concret pentru cazul particular al determinarii ponderilor dendritelor pentru nivelul 3 intr-o retea neurala cu 5 nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire): \frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial E}{\partial a_5} * \frac{\partial E}{\partial a_5} * \frac{\partial E}{\partial a_4} * \frac{\partial E}{\partial a_4} * \frac{\partial E}{\partial a_4} * \frac{\partial E}{\partial a_3} * \frac{\partial E}{\partial a_3} * \frac{\partial E}{\partial a_3} In cazul de mai sus vectorul/variabile \Theta este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat La nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python) Variante de modele Varianta A: in primul stadiu al experimentarii se propune un model$				
$E = \sqrt{\frac{(Out_{corect} - A_n)^2}{2}}$ - Invatarea efectiva consta in ajustarea ponderilor (vectorii/matricile W(i,j) unde i,j reprezinta nivelele retelei neurala) automatizata se realizeaza prin metoda propagarii inapoi a gradientului erorii determinate si prezentate anterior. Concret pentru cazul particular al determinarii ponderilor dendritelor pentru nivelul 3 intr-o retea neurala cu 5 nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire): $\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial a_5} * \frac{\partial z_5}{\partial a_4} * \frac{\partial a_4}{\partial a_4} * \frac{\partial z_4}{\partial a_3} * \frac{\partial a_3}{\partial a_3} * \frac{\partial z_3}{\partial a_3}$ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		- In final se calculeaza eroarea intre valoarea multi-nomiala		
Invatarea efectiva consta in ajustarea ponderilor (vectorii/matricile W(i,j) unde i,j reprezinta nivelele retelei neurala) automatizata se realizeaza prin metoda propagarii inapoi a gradientului erorii determinate si prezentate anterior. Concret pentru cazul particular al determinarii ponderilor dendritelor pentru nivelul 3 intr-o retea neurala cu 5 nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire): $\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial a_5}{\partial a_4} * \frac{\partial a_4}{\partial z_4} * \frac{\partial a_4}{\partial a_3} * \frac{\partial a_3}{\partial z_3} * \frac{\partial a_3}{\partial \theta_3}$ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multi- platforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un micro- interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		asteptata si cea rezultata din functie ipoteza cu:		
(vectorii/matricile W(i,j) unde i,j reprezinta nivelele reteleineurala) automatizata se realizeaza prin metoda propagariiinapoi a gradientului erorii determinate si prezentateanterior. Concret pentru cazul particular al determinariiponderilor dendritelor pentru nivelul 3 intr-o retea neuralacu 5 nivele (nivelul 5 fiind nivelul de calcul final alvectorului multi-nomial de iesire): $\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial a_5}{\partial a_4} * \frac{\partial a_4}{\partial a_4} * \frac{\partial a_3}{\partial a_3} * \frac{\partial a_3}{\partial a_3} * \frac{\partial a_3}{\partial \theta_3}$ In cazul de mai sus vectorul/variabile Θ este echivalenta cuW. Ajustarea efectiva a ponderilor din matricile respectivese face prin aplicarea unui algoritm de tip gradient-descent- ajustarea periodica cu fragmente ale gradientului pana laatingerea unui minim al functiei de cost E.Metoda de implementareImplementarea se va realiza prin utilizarea unui limbaj de tip multi-platforma independent de dispozitivul hardware – in cazul de fatalimbajul Python.Mediul de rulare la nivelulLa nivelul dispozitivului incorporat se va utiliza un micro-interpretor Python capabil sa ruleze pe dispozitive cu capacitatiextrem de reduse (Embedded Python)		$E = \sqrt{\frac{(Out_{corect} - A_n)^2}{2}}$		
neurala) automatizata se realizeaza prin metoda propagarii inapoi a gradientului erorii determinate si prezentate anterior. Concret pentru cazul particular al determinarii ponderilor dendritelor pentru nivelul 3 intr-o retea neurala cu 5 nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire): $\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial a_5} * \frac{\partial a_5}{\partial a_4} * \frac{\partial a_4}{\partial a_4} * \frac{\partial a_4}{\partial a_3} * \frac{\partial a_3}{\partial a_3} * \frac{\partial z_3}{\partial \theta_3}$ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul La nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		- Invatarea efectiva consta in ajustarea ponderilor		
inapoi a gradientului erorii determinate si prezentate anterior. Concret pentru cazul particular al determinarii ponderilor dendritelor pentru nivelul 3 intr-o retea neurala cu 5 nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire): $ \frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial a_5}{\partial a_4} * \frac{\partial a_4}{\partial a_4} * \frac{\partial a_3}{\partial a_3} * \frac{\partial a_3}{\partial a_3} * \frac{\partial a_3}{\partial \theta_3} $ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat La nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		(vectorii/matricile W(i,j) unde i,j reprezinta nivelele retelei		
anterior. Concret pentru cazul particular al determinarii ponderilor dendritelor pentru nivelul 3 intr-o retea neurala cu 5 nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire): $ \frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial z_5}{\partial a_4} * \frac{\partial a_4}{\partial z_4} * \frac{\partial z_4}{\partial a_3} * \frac{\partial a_3}{\partial z_3} * \frac{\partial z_3}{\partial \theta_3} $ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		neurala) automatizata se realizeaza prin metoda propagarii		
ponderilor dendritelor pentru nivelul 3 intr-o retea neurala cu 5 nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire): $\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial a_5}{\partial a_4} * \frac{\partial a_4}{\partial a_4} * \frac{\partial a_4}{\partial a_3} * \frac{\partial a_3}{\partial a_3} * \frac{\partial z_3}{\partial \theta_3}$ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware — in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		inapoi a gradientului erorii determinate si prezentate		
$ cu 5 \text{ nivele (nivelul 5 fiind nivelul de calcul final al vectorului multi-nomial de iesire):} $ $ \frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial a_5}{\partial a_4} * \frac{\partial a_4}{\partial a_4} * \frac{\partial a_4}{\partial a_3} * \frac{\partial a_3}{\partial z_3} * \frac{\partial a_3}{\partial a_3} $ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. $ \text{Metoda de implementare} \qquad \text{Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python.} $ $ \text{Mediul de rulare la nivelul} \qquad \text{La nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python) } $		anterior. Concret pentru cazul particular al determinarii		
vectorului multi-nomial de iesire): $\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial a_5}{\partial a_4} * \frac{\partial a_4}{\partial z_4} * \frac{\partial a_4}{\partial a_3} * \frac{\partial a_3}{\partial z_3} * \frac{\partial z_3}{\partial \theta_3}$ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		ponderilor dendritelor pentru nivelul 3 intr-o retea neurala		
$\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial z_5}{\partial a_4} * \frac{\partial a_4}{\partial z_4} * \frac{\partial z_4}{\partial a_3} * \frac{\partial a_3}{\partial z_3} * \frac{\partial z_3}{\partial \theta_3}$ In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		cu 5 nivele (nivelul 5 fiind nivelul de calcul final al		
In cazul de mai sus vectorul/variabile Θ este echivalenta cu W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multi- platforma independent de dispozitivul hardware — in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un micro- interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		vectorului multi-nomial de iesire):		
W. Ajustarea efectiva a ponderilor din matricile respective se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul La nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		$\frac{\partial E}{\partial \theta_3} = \frac{\partial E}{\partial a_5} * \frac{\partial a_5}{\partial z_5} * \frac{\partial z_5}{\partial a_4} * \frac{\partial a_4}{\partial z_4} * \frac{\partial z_4}{\partial a_3} * \frac{\partial a_3}{\partial z_3} * \frac{\partial z_3}{\partial \theta_3}$		
se face prin aplicarea unui algoritm de tip gradient-descent - ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multi- platforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un micro- interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		In cazul de mai sus vectorul/variabile Θ este echivalenta cu		
- ajustarea periodica cu fragmente ale gradientului pana la atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		W. Ajustarea efectiva a ponderilor din matricile respective		
Atingerea unui minim al functiei de cost E. Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un microinterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		se face prin aplicarea unui algoritm de tip gradient-descent		
Metoda de implementare Implementarea se va realiza prin utilizarea unui limbaj de tip multiplatforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		- ajustarea periodica cu fragmente ale gradientului pana la		
platforma independent de dispozitivul hardware – in cazul de fata limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un micro-interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		atingerea unui minim al functiei de cost E.		
limbajul Python. Mediul de rulare la nivelul dispozitivului incorporat se va utiliza un micro- interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)	Metoda de implementare	Implementarea se va realiza prin utilizarea unui limbaj de tip multi-		
Mediul de rulare la nivelul dispozitivului incorporat linterpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		platforma independent de dispozitivul hardware – in cazul de fata		
dispozitivului incorporat interpretor Python capabil sa ruleze pe dispozitive cu capacitati extrem de reduse (Embedded Python)		limbajul Python.		
extrem de reduse (Embedded Python)	Mediul de rulare la nivelul	La nivelul dispozitivului incorporat se va utiliza un micro-		
	dispozitivului incorporat	interpretor Python capabil sa ruleze pe dispozitive cu capacitati		
Variante de modele Varianta A: in primul stadiu al experimentarii se propune un model		extrem de reduse (Embedded Python)		
	Variante de modele	Varianta A: in primul stadiu al experimentarii se propune un model		
propuse cu invatare superficiala specializat pe functionarea in medii on-line	propuse	cu invatare superficiala specializat pe functionarea in medii on-line		

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

+4 031 4055287 +4 031 4012234 +4 0721 368 127

Website: http://www.4esoft.com email: office@4esoft.com

Varianta B: in stadiul avansat al proiectului se va face trecerea de la modelul superficial la un model cu parametrizare adanca de tip retea convolutionala adanca

Anexa 1 - Cod sursa modul predictiv bazat pe arhitectura superficiala

```
# -*- coding: utf-8 -*-
@application: Online Classifier Engine
@created: 2017-01-04
@author: 4E SOFTWARE SRL
_____
   Momentum/Velocity for Online learning setting
   NEO LineSearch (adapted for online)
   VotingClassification
.....
import pandas as pd
import numpy as np
from scipy.special import expit
from scipy import stats
import matplotlib.pyplot as plt # for debug error plotting
from time import time
import sys
class oce utils:
   def FeatureNormalize(self, X data, method = 'z-score'):
       if method == 'z-score':
           min_val = X_data.mean(axis=0)
           div_val = X_data.std(axis=0)
       elif method =="minmax":
            ## min-max
```

email: office@4esoft.com

Website: http://www.4esoft.com

all ex = TP[0]+TN[0]+FP[0]+FN[0]

observed_accuracy = np.sum(TP) / all_ex

```
http://www.4esoft.com
        min val = X data.min(axis=0)
        div val = X data.max(axis=0)
        raise Exception("Unknown scale/norm method: "+str(method))
    \operatorname{div} \operatorname{val}[\operatorname{div} \operatorname{val} == 0] = 1.
    X norm = X data - min val
    X norm = np.array(X norm, dtype = float) / div val
   return X_norm, min_val, div_val
def TestDataNormalize(self, X test, min val, div val):
   X norm = X test - min val
   X norm = np.array(X norm, dtype = float) / div val
   return X norm
def loaddata(self, file):
    return pd.read csv(file)
# Kappa: duplicated and generalized from OnlineClassifier version
def Kappa(self,y_pred,y_truth, classes):
   nr classes = len(classes)
   classes = list(classes)
   TP = np.zeros(shape=(nr_classes))
   FP = np.zeros(shape=(nr classes))
    TN = np.zeros(shape=(nr classes))
   FN = np.zeros(shape=(nr classes))
    class_pred = np.zeros(shape=(nr_classes))
    class_real = np.zeros(shape=(nr_classes))
    for (i,c class) in zip(range(nr classes), classes):
       TP[i] = np.logical_and( y_pred == c_class, y_truth == c_class ).sum()
        TN[i] = np.logical and( y pred != c class, y truth != c class ).sum()
        FP[i] = np.logical_and( y_pred == c_class, y_truth != c_class ).sum()
        FN[i] = np.logical_and( y_pred != c_class, y_truth == c_class ).sum()
        class pred[i] = TP[i] + FP[i]
        class real[i] = TP[i] + FN[i]
```

Website: http://www.4esoft.com

```
expected accuracy = (np.sum(class pred*class real) / all ex) / all ex
    kappa = (observed_accuracy - expected_accuracy) / \
            (1 - expected accuracy)
    # conf matrix !!!
    return kappa
\# ROC: duplicated and generalized from OnlineClassifier version
def ROC(self, y prc, y label, labels):
    nr_labels = len(labels)
   if y label.ndim>1:
       y label list=y label[:,0]
   thresholds = np.linspace(1, 0, 101)
    if nr labels == 2:
        nr ROCs = 1
    else:
        nr ROCs = nr labels
   TPR = np.zeros(shape=(101,nr ROCs))
    FPR = np.zeros(shape=(101,nr ROCs))
   AUC = np.zeros(shape=(nr ROCs))
    for cROC in range(nr_ROCs):
        if nr ROCs==1:
            c label=1
        else:
            c_label = labels[cROC]
        for i in range(101):
            c thr = thresholds[i]
            # Classifier / label agree and disagreements for current threshold.
            if i==50:
                k=1
            \label{eq:tp} \mbox{TP = np.logical\_and( y\_prc[:,cROC] > c\_thr, y\_label\_list==c\_label ).sum()}
            TN = np.logical and( y prc[:,cROC] <=c thr, y label list!=c label ).sum()</pre>
            FP = np.logical_and( y_prc[:,cROC] > c_thr, y_label_list!=c_label ).sum()
            FN = np.logical_and( y_prc[:,cROC] <=c_thr, y_label_list==c_label ).sum()</pre>
            # Compute false positive rate for current threshold.
            FPR[i,cROC] = FP / float(FP + TN)
            # Compute true positive rate for current threshold.
            TPR[i,cROC] = TP / float(TP + FN)
```

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

+4 031 4055287 +4 031 4012234 +4 0721 368 127

email: office@4esoft.com

```
# compute the AUC score for the ROC curve using the trapezoidal method
            AUC[cROC] = 0.
            for i in range(100):
               AUC[cROC] += (FPR[i+1,cROC]-FPR[i,cROC]) * (TPR[i+1,cROC]+TPR[i,cROC])
           AUC[cROC] *= 0.5
       return TPR, FPR, AUC
   ## train_online_classifier() simulates a real life
   ## feed of data to our OnlineClassifier
   ## cross-validation is used to obtain best J(Theta)
   def train online classifier(self, clf, X_train,y_train, X_cross = None,y_cross =
None, batch size=1):
       nr_examples = X_train.shape[0]
       nr batches = nr examples / batch size
       for i in range(nr batches):
           xi = X train[(i*batch size):((i+1)*batch size),:]
           yi = y train[(i*batch size):((i+1)*batch size)]
           clf.OnlineTrain(xi,yi,X cross=X cross,y cross=y cross)
       return clf
   ##
   ## ck train online classifier() simulates a real life
   ## feed of data to our OnlineClassifier
   ##
   def ck_train_online_classifier(self, clf, X_train,y_train, X_cross = None,y_cross =
None, batch_size=1):
       nr examples = X train.shape[0]
       nr batches = nr examples / batch size
       for i in range(nr batches):
           xi = X_train[(i*batch_size):((i+1)*batch_size),:]
           yi = y train[(i*batch size):((i+1)*batch size)]
           clf.OnlineTrain(xi,yi,X_cross=X_cross,y_cross=y_cross)
        return clf
## implement OnlineClassifier
```

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

+4 031 4055287 +4 031 4012234 +4 0721 368 127

email: office@4esoft.com

```
## both multi-class (one-vs-all) and single-class logistic regression
## y is either multi-class or True/False
##
class OnlineClassifier:
   def init (self,nr features,classes=[0,1],
                 alpha=1.0, DecreasingAlpha=False,
                 alpha coef=-1, softmax alpha search = False,
                 polyfeats=1, method='sigmoid',
                lmbd=0,
                random init=False,
                Verbose = 5, NoVerbose = False,
                back train = 1):
        self.back train = back train
        self.softmax alpha search = softmax alpha search
       self.alpha search epochs = 100
        self.alpha search iter = 0;
        self.Classes = list(classes) # class labels binary default
       self.eps = 1e-15 # constant used for clipping
        self.Verbose = Verbose # this is the verbose level: the higher the most-import-only
info is displayed
        self.NoVerbose = NoVerbose # force to ignore Verbose property
       self. standard binary classes = [0,1]
       self.lmbd = lmbd # lambda for reguralization DEFAULT 0 (no reg)
        self.methods = ['softmax','sigmoid','perceptron'] #"methodation" function
       if not (method in self.methods):
           raise Exception ("Unknown method: "+method)
       self.method = method # can be default='sigmoid' or 'softmax'
       self.DecreasingAlpha = DecreasingAlpha # alpha gradient step decreases ?
       self.alpha coef = alpha coef  # coef for alpha decrease = actually not used
        self.base_alpha = alpha
                                   # alpha
       self.nr Classes = len(self.Classes) #
                                              number of classes (2 default)
       self.original n = nr features +1 # original number of features MUST be precoded
includes intercept
       self.n = nr features*polyfeats + 1 # number of features +1 (poly features + 1 used
only if poly = true)
       self.m = 0
       self.alpha = alpha
        self.alpha 0 = alpha
       self.alpha array = np.empty((0,1),float)
        self.MultiClass = False
       if method == 'sigmoid':
           self.Costs = np.empty((0,self.nr_Classes), float)
```

email: office@4esoft.com

```
self.J array = np.empty((0,self.nr Classes), float)
else:
    self.Costs = np.empty((1,0), float)
    self.J_array = np.empty((1,0), float)
self.xi = np.array([])
self.y = None
self.BestAccuracy = 0
self.BestFeed = 0
self.polyfeats = polyfeats # >1 if using polynomial feats remapping
self.all X = np.empty((0, self.n), float) # all xi in one matrix
self.all_y = np.empty((0), dtype = object)
\operatorname{nr} thetas=1
if (self.nr Classes>2) or (self.method == 'softmax'):
    nr thetas=self.nr Classes
    self.MultiClass = True
self.BestTheta = None
self.random init = random init
if random_init:
    ###
    ### random Theta initilization
    ### wih "noise" values (-0.05 to +0.05)
    self.Theta = np.random.uniform(low=-0.05, high=0.05, size=(self.n,nr thetas))
else:
    self.Theta = np.zeros(shape=(self.n,nr thetas))
\#\# now we need a mechanism to preserve all gradients for each class
## we will use a 3d matrix (iteration, class, actual theta)
## this way we can analyse exploding gradients
self.gradients = np.empty((0,nr thetas,self.n),float)
self._nr_thetas = nr_thetas
self.LastGrad = None
self.LastYOHM = None
self.LastYHat = None
self.LastYERR = None
self.LastGThe = None
self.LastThet = None
self.LastJ = None
self.LastAlph = None
self.BestAlphas = list()
```

email: office@4esoft.com

Website: http://www.4esoft.com

def DebugInfo(self, Value, lvl=0):

```
def SearchBestAlpha(self,x, ohmy, Verbose = True):
   bestAlpha = 0
   bestDiff = -1e100
    if self.LastJ == None:
       return bestAlpha
   alphas = np.array([1e-5,5e-5,1e-4,5e-4,1e-3,5e-3,1e-2,5e-2,0.1,0.5,1,5])
   diff list = list()
    for i in range(alphas.size):
        test alpha = alphas[i]
        ##
        ## now compute test weights based on previous weights
        ## updated with previous gradient and tested alpha
        ## then compute current J(theta) and determine
        ## best previous update step (best previous alpha)
        TestTheta = self.LastGThe - test_alpha*self.LastGrad
       m = np.float64(x.shape[0])
                                        # batch update size not all obs !!!
        Theta = np.array(TestTheta)
       xT = x.dot(Theta)
        yhat = self.softmax(xT)
        yhat = np.clip(yhat,self.eps,1-self.eps)
        # now final calc incl reguralization
        J = self. log loss reg(ohmy, yhat, self.lmbd, Theta, m)
        J_diff = self.LastJ - J
        diff list.append(J diff)
        if J diff > bestDiff:
           bestAlpha = test alpha
           bestDiff = J diff
    if Verbose:
        self.DebugInfo("[DEBUG]
                                  BestAlpha = {:.5f}".format(bestAlpha), 10)
    self.alpha_search_iter = self.alpha_search_iter + 1
    return bestAlpha
```

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

+4 031 4055287 +4 031 4012234 +4 0721 368 127

email: office@4esoft.com

```
if self.NoVerbose:
        return
    if lvl<=self.Verbose:
       return
    text = ""
    #text = str(type(Value))
    #text += ':\n'
    text += str(Value)
    if self.Verbose:
       print text
       sys.stdout.flush()
def GetShortHyperParams(self):
    return "Method={} Poly={} BatchSize={} Alpha0={}".format(self.method,
                                                              self.polyfeats,
                                                              self.batchsize,
                                                              self.alpha 0)
def GetHyperParams(self):
    str params = "\nHyper Parameters:"
    str params += "\nHyFunction: "+str(self.method)
    str params += "\nAlpha-init: "+str(self.alpha 0)
    str params += "\nDecrAlpha : "+str(self.DecreasingAlpha)
    str params += "\nAlphaCoef : "+str(self.alpha coef)
    str_params += "\nSM-alpsrch: "+str(self.softmax_alpha_search)
    str params += "\nAlpha-last: "+str(self.alpha array[-3:])
    str params += "\nPolynomial: "+str(self.polyfeats)
    str_params += "\nClasses : "+str(self.Classes)
    str params += "\nRegLambda : "+str(self.lmbd)
    str params += "\nRandTheta : "+str(self.random init)
    str params += "\n"
    return str_params
def Kappa(self,y_pred,y_truth, classes):
   nr classes = len(classes)
   classes = list(classes)
   TP = np.zeros(shape=(nr classes))
   FP = np.zeros(shape=(nr classes))
   TN = np.zeros(shape=(nr classes))
    FN = np.zeros(shape=(nr classes))
    class pred = np.zeros(shape=(nr classes))
    class real = np.zeros(shape=(nr classes))
    for (i,c_class) in zip(range(nr_classes),classes):
```

email: office@4esoft.com



```
TP[i] = np.logical and( y pred == c class, y truth == c class ).sum()
        TN[i] = np.logical_and( y_pred != c_class, y_truth != c_class ).sum()
        FP[i] = np.logical and( y pred == c class, y truth != c class ).sum()
        FN[i] = np.logical_and( y_pred != c_class, y_truth == c_class ).sum()
        class_pred[i] = TP[i] + FP[i]
        class real[i] = TP[i] + FN[i]
    all ex = TP[0]+TN[0]+FP[0]+FN[0]
    observed accuracy = np.sum(TP) / all ex
    expected accuracy = (np.sum(class pred*class real) / all ex) / all ex
    kappa = (observed_accuracy - expected_accuracy) / \
            (1 - expected accuracy)
    # conf matrix !!!
    return kappa
def ROC(self, y prc, y label, labels):
    nr labels = len(labels)
    if y label.ndim>1:
        y_label_list=y_label[:,0]
    thresholds = np.linspace(1, 0, 101)
    if nr labels == 2:
       nr ROCs = 1
    else:
       nr ROCs = nr labels
    TPR = np.zeros(shape=(101,nr ROCs))
    FPR = np.zeros(shape=(101,nr ROCs))
    AUC = np.zeros(shape=(nr_ROCs))
    for cROC in range(nr ROCs):
        if nr ROCs==1:
            c_label=1
        else:
            c_label = labels[cROC]
        for i in range(101):
           c thr = thresholds[i]
            # Classifier / label agree and disagreements for current threshold.
            if i==50:
                k=1
            TP = np.logical_and( y_prc[:,cROC] > c_thr, y_label_list==c_label ).sum()
            TN = np.logical and( y prc[:,cROC] <=c thr, y label list!=c label ).sum()</pre>
            FP = np.logical and( y prc[:,cROC] > c thr, y label list!=c label ).sum()
            FN = np.logical and( y prc[:,cROC] <=c thr, y label list==c label ).sum()</pre>
```

email: office@4esoft.com

```
# Compute false positive rate for current threshold.
            FPR[i,cROC] = FP / float(FP + TN)
            # Compute true positive rate for current threshold.
            TPR[i, cROC] = TP / float(TP + FN)
        # compute the AUC score for the ROC curve using the trapezoidal method
        AUC[cROC] = 0.
        for i in range(100):
            AUC[cROC] += (FPR[i+1,cROC]-FPR[i,cROC]) * (TPR[i+1,cROC]+TPR[i,cROC])
        AUC[cROC] *= 0.5
    return TPR, FPR, AUC
def GetConfusionMatrix(self, y_pred,y_label):
   nr_preds = y_pred.size
   pred_classes = np.unique(y_pred)
   labl_classes = np.unique(y_label)
   all classes = np.unique(np.r [pred classes,labl classes])
   conf df = pd.DataFrame(index= all classes ,columns = all classes)
   conf df.index.name = "Truth"
    for row in range(all_classes.size):
        for col in range(all classes.size):
           c_preds = y_pred==all_classes[col]
            c_label = y_label == all_classes[row]
           val = np.logical and( c preds , c label ).sum()
            conf df.at[all classes[row],all classes[col]]= val
    return conf_df
def add observation(self, x, y):
    self.all X = np.r [self.all X, x]
    self.all_y = np.append(self.all_y,y)
    return
def get train obs(self):
   nr all x = self.all X.shape[0]
   last_obs = np.arange(nr_all_x-self.batchsize,nr_all_x)
```

Website: http://www.4esoft.com

```
nr obs = int(round(self.batchsize * self.back train))
       extra_obs = nr_obs - self.batchsize
       if (nr all x \ge nr obs) and (extra obs>0):
           old idx = np.arange(0,nr all x -self.batchsize)
           np.random.shuffle(old idx)
           all obs = np.append(old idx[:extra obs], last obs)
       else:
           all_obs = last_obs
       xi = self.all X[all obs,:]
       yi = self.all y[all obs]
       return xi,yi
   def prepare x(self, x): # add intercept and poly feats
        # convert to a 1xN matrix if single observation
       x temp = np.array(x,ndmin=2)
       x prepared = np.array(x temp)
       mini batch size = x prepared.shape[0]
       ones_column = np.ones(shape=(mini_batch_size))
       x prepared = np.c [ones column,x prepared] # add intercept
       if self.polyfeats>1:
            for rank in range (2,self.polyfeats+1):
                x prepared = np.c [x prepared, np.power(x temp,rank)]
       return x prepared
   def Calc pValues(self):
       yHat,ydf = self.Predict(self.all_X)
       y = self.all y
       X = self.all X
        ## THIS IS NOT YET OK !
        sse = np.sum((yHat - y) ** 2, axis=0) / float(X.shape[0] - X.shape[1])
        \#se = np.array([np.sqrt(np.diagonal(sse[i] * np.linalg.inv(np.dot(X.T, X))))) for i in
range(sse.shape[0]) ])
        se = np.array([np.sqrt(np.diagonal(sse * np.linalg.inv(np.dot(X.T, X))))])
       self.t = self.Theta / se
        self.p = 2 * (1 - stats.t.cdf(np.abs(self.t), y.shape[0] - X.shape[1]))
```

xT = x.dot(Theta)HT = self.sigmoid(xT)

```
email: office@4esoft.com
           http://www.4esoft.com
    return self
def softmax(self,z):
   # z is MxK where M=observation K=classes
    # first shift the values of f so that the
    # highest number is 0:
    z = np.max(z)
   ez = np.exp(z)
   p = (ez.T / np.sum(ez, axis=1)).T
   return p
def sigmoid(self,z):
   return expit(z)
   \#return 1 / (1 + math.exp(-z))
def _simple_cross_entropy_loss(self, y, ht):
   # two class cross-entropy
   crs entr loss = (-1.0) * np.sum(y*np.log(ht)+(1-y)*np.log(1-ht))
   return crs_entr_loss
def CostFunctionLogistic(self,i_theta,x,y):
   # implements sigmoid logistic cost function and grad,
    # i theta = current theta
    # works both for single and mini-batch updates !
    if self.method != 'sigmoid':
       raise Exception('Sigmoid cost function called from non-sigmoid classifier')
    if x.ndim != 2:
       raise Exception('Sigmoid function received x with ndim!=2')
   m = np.float64(x.shape[0])  # batch update size !!! NOT ALL OBS
   Theta = np.array(self.Theta[:,i_theta])
   Theta0 = np.array(Theta)
   Theta0[0] = 0
```

Website: http://www.4esoft.com

```
HT = np.clip(HT,self.eps,1-self.eps)
    H = HT - y
    # cost for linear regression
    # cCostRegression = (1/float(2))*np.power(H,2)
    # cross-entropy cost function
    cCost1 = self. simple cross entropy loss(y,HT)
    cCost2 = cCost1 / (float(m))
    # end cross-entropy cost function
    # ADD REGURALIZATION
    # default lmbd is 0 so no reg by default
    cCost = cCost2 + (self.lmbd) / (2 * m) * np.sum(Theta0.T.dot(Theta0))
    Grad = (1.0 / m) * x.T.dot(H)
    #ADD REGURALIZATION
    Grad += (self.lmbd / m) * Theta0
    if np.isnan(cCost):
        self.DebugInfo("[ERROR] NaN Cost",100)
       prev grads = self.gradients[:,i theta,:]
        sum vector = np.sum(prev grads, axis = 1)
       plt.plot(range(self.m-1), sum vector[:-1])
        plt.show()
        cls = i theta
        itr = self.m
        self.DebugInfo("[ERROR] Grad norm vect= {}".format(sum_vector),100)
        str E = "[ERROR]NaN cost Theta={} at batch no. {} ".format(cls,itr)
        str E += \n \nMaxX={:.2f} MinX={:.2f}".format(np.max(x),np.min(x))
        str_E += "\nMaxT = {:.2f} MinT = {:.2f}".format(np.max(Theta), np.min(Theta))
        str E += "\nX.dot.Theta={}".format(xT)
        str E += self.GetHyperParams()
        raise Exception(str E)
    return Grad, cCost
def LogisticTrain(self,xi, yi):
    \#\#\# 1 step stohastic logistic classifier training based on
    ### multi-class logistic
    # prepare gradient storage
    self.gradients = np.append(self.gradients,
```

```
Website:
http://www.4esoft.com
```

```
np.zeros(shape=(1,
                                           self. nr thetas,
                                           self.n)), axis = 0)
if yi.ndim>1:
   yi = np.ravel(yi)
if self.MultiClass:
   #find right theta for each class !!!
   y coded = np.empty(shape=(yi.size))
    cCosts = np.zeros(shape=(1,self.nr Classes))
    for i in range(self.nr Classes):
       y coded.fill(0)
       if y coded.size == 1:
           y coded[0] = (yi == self.Classes[i])
        else:
            y coded[yi==self.Classes[i]] = 1
        Grad, cCost = self.CostFunctionLogistic(i,xi,y coded)
        ### store gradient
        self.gradients[-1,i,:] = Grad
       ### done store gradient
        self.Theta[:,i] = self.Theta[:,i] - self.alpha*Grad
        cCosts[0,i] = cCost
    self.Costs = np.append(self.Costs,cCosts,axis=0)
    J = np.empty((1,self.nr Classes), float)
    J[0,:] = np.nanmean(self.Costs,axis=0)
    self.J array = np.append(self.J array, J, axis=0)
    ## done multi class
else:
    ## now for single class
    ##
    ic = 0
    Grad, cCost = self.CostFunctionLogistic(i c,xi,yi)
    self.Theta[:,i_c] = self.Theta[:,i_c] - self.alpha*Grad
    self.Costs = np.append(self.Costs,cCost)
    ### store gradient
    self.gradients[-1,0,:] = Grad
    ### done store gradient
    J = np.sum(self.Costs)/self.Costs.shape[0]
    self.J_array = np.append(self.J_array, J)
    ## done single class
    ##
return J
```

Str Gheorghe Titeica nr 6, Sector 2, Bucuresti Romania

+4 031 4055287 +4 031 4012234 +4 0721 368 127

email: office@4esoft.com

```
def log loss(self,y,y pred):
    ## Generalized cross-entropy. y input is a OneHot matrix
    J matrix = y*np.log(y pred)
    J =-np.sum(J matrix)
    return J
def _log_loss_reg(self,y,y_pred,lmbd, theta, m):
   J_temp = self._log_loss(y,y_pred)
    # now apply ridge (L2) regularization
    J \text{ temp} = J \text{ temp} / m + 0.5 * lmbd * np.sum(theta*theta)
    return J temp
def CostFunctionSoftmax(self,x, ohm y):
    ### 1 step stohastic softmax training based on gradiend descent
    \#\#\# works BOTH for single observation and multiple observations
    ### y is not
    if self.method != 'softmax':
        raise Exception('Softmax function called from non-softmax classifier')
    if x.ndim != 2:
        raise Exception('Softmax function received x with ndim!=2')
    m = np.float64(x.shape[0])
                                    # batch update size not all obs !!!
    Theta = np.array(self.Theta)
    xT = x.dot(Theta)
    yhat = self.softmax(xT)
    yhat = np.clip(yhat,self.eps,1-self.eps)
    # now final calc incl reguralization
    J = self. log loss reg(ohm y, yhat, self.lmbd, Theta, m)
    self.LastGThe = Theta
    self.LastM = m
    TempG = ohm y - yhat
    self.LastYERR = TempG
    self.LastYHAT = yhat
    self.LastYOHM = ohm y
    self.LastObs = x
    Grad = (-1.0/m) * x.T.dot(TempG)
```

email: office@4esoft.com

```
Grad += self.lmbd*Theta
    return Grad, J
def SoftmaxTrain(self,xi,yi):
    cur m = xi.shape[0]
    SparseBoolLabels = np.zeros(shape=(cur m,self.nr Classes))
    softmax_y = np.zeros(shape=(cur_m,1))
    for i,k in zip(range(self.nr Classes), self.Classes):
        where y = np.where(yi==k)
        if where y[0].size>0:
            if len(where y)>1:
                row, column = where y
            else:
                row = where_y
            softmax y[row] = i+1
            # now calculate 1(Yi==col) sparse boolean matrix
            SparseBoolLabels[row,i] = 1
    ,, ,, ,,
    else: ???
       self.SparseBoolLabels = np.zeros(shape=(1,self.nr Classes))
        self.SparseBoolLabels[self.Classes==yi] = 1
    # prepare gradient storage
    self.gradients = np.append(self.gradients,
                               np.zeros(shape=(1,
                                                self.nr_Classes,
                                                self.n)), axis = 0)
    if self.alpha search iter == 200:
       test_stop = True
    ### now the gradient descent step
    if self.softmax_alpha_search:
        if self.alpha search iter < self.alpha search epochs:
            bestAlpha = self.SearchBestAlpha(xi,SparseBoolLabels, Verbose = False)
            self.alpha = bestAlpha
            self.BestAlphas.append(bestAlpha)
    Grad, J = self.CostFunctionSoftmax(xi,SparseBoolLabels)
```

email: office@4esoft.com

```
self.LastGrad = Grad
        self.LastJ = J
        ### store gradient
       self.gradients[-1,:,:] = Grad.T
       ### done store gradient
       self.Theta = self.Theta - self.alpha*Grad
       self.LastAlph = self.alpha
       self.LastThet = self.Theta
       self.Costs = np.append(self.Costs, J)
       Jmean = np.sum(self.Costs)/self.Costs.shape[0]
       self.J_array = np.append(self.J_array, Jmean)
       return J
   ## Stohastic Gradient Check with option of selecting best weights
   ## based on cross dataset
   ##
   def OnlineTrain(self,x_input, y_input, X_cross = None, y_cross = None):
        """ obsolete since mini batch
        ## data comes in only 1 dim
       if x input.shape[0]!=(self.original n-1):
           raise Exception("Check your data ! x has wrong size (expected="+str(self.n-1)+"
received='+x input.shape[1]+')')
       xi = self.prepare x(x input)
       self.batchsize = xi.shape[0]
       yi = np.array(y_input)
        ## now add the observation to observation matrices
        self.add observation(xi,yi)
        ## now prepare actual Xi
       xi,yi = self.get_train_obs()
```

Website: http://www.4esoft.com

```
if (self.m == 0):
           self.DebugInfo("[DEBUG] Beginning training: "+self.GetShortHyperParams(), 10)
        #now increment nr of received examples
        self.m+=1
       if (self.m % 100) ==0:
           self.DebugInfo("[DEBUG] Training the observation/batch nr {}".format(self.m),
10)
       if self.method == 'sigmoid': # sigmoid/logistic single or multi class
           J = self.LogisticTrain(xi,yi)
       elif self.method == 'softmax': # softmax
           J = self.SoftmaxTrain(xi,yi)
       self.alpha_array = np.append(self.alpha_array, self.alpha)
       if self.DecreasingAlpha:
           N = 1 #batch size
           if self.alpha coef>0:
               self.alpha = self.alpha * self.alpha coef
           else:
               self.alpha = float(self.alpha 0) / (1.0 + (self.m / N))
        ## now cross check
        ##
        if (not (X cross is None)) and (not (y cross is None)):
           y cross pred, ydf = self.Predict(X cross)
           y1 = np.ravel(y_cross_pred)
           y2 = np.ravel(y_cross)
           preds = y1 == y2
           my_pred = (np.sum(preds)/float(X_cross.shape[0]))*100
           if my pred>=self.BestAccuracy:
               self.BestAccuracy = my pred
               self.BestTheta = np.array(self.Theta)
               self.BestFeed = self.m
        else:
           self.BestTheta = np.array(self.Theta)
           self.BestFeed = self.m
        return J
```

email: office@4esoft.com

```
def PredictSoftmax(self,X,Theta,real y):
   y = None
   y floats = None
   m=X.shape[0]
   X = self.prepare_x(X) \# add poly, intercept
    y floats = self.softmax(X.dot(Theta))
   y indices = np.argmax(y floats,axis=1)
   y = np.empty((0,1))
    for i,label in zip(range(m),y_indices):
        y = np.append(y,np.array([[self.Classes[label]]]),axis=0)
    return y,y floats
def PredictSigmoid(self,X,Theta,real y):
   m=X.shape[0]
   X = self.prepare_x(X) # add poly, intercept
    if self.MultiClass:
        # predict multi class
       y floats = self.sigmoid(X.dot(Theta))
        y indices = np.argmax(y floats,axis=1)
        y = np.empty((0,1))
        for i,label in zip(range(m),y_indices):
            y = np.append(y,np.array([[self.Classes[label]]]),axis=0)
    else:
        # predict single class 0/1
        y floats = self.sigmoid (X.dot(Theta))
        y = np.round(y floats)
    return y, y_floats
def Predict(self, X,real_y = None, Best = False, return_floats = False, return_df = True):
    if Best:
        if self.BestTheta is None:
            raise Exception("BestTheta is "+self.BestTheta.tostring())
        Theta = self.BestTheta
    else:
       Theta = self.Theta
    if self.method == 'sigmoid':
       y,y floats = self. PredictSigmoid(X,Theta,real y)
    elif self.method == 'softmax':
```

email: office@4esoft.com

Website: http://www.4esoft.com

raise Exception("Class only file")

```
y,y floats = self. PredictSoftmax(X,Theta,real y)
       else:
           raise Exception ("Unknown method: "+self.method)
       if (self.Classes == self._standard_binary_classes) and \
           (self.nr_Classes==2):
           if self.method == 'softmax':
               columns=["0","1"]
               columns=["0/1"]
       else:
           columns = self.Classes
       y_df = pd.DataFrame(y_floats,columns=columns)
       if not (real_y is None):
           y_df['Real Y'] = real_y
       y = np.ravel(y)
       if return floats:
           return y,y_df,y_floats
           if return_df:
              return y,y_df
            else:
               return y
###
### End OnlineClassifier class
###
if __name__ == '__main__':
```